

Case Engenharia de Dados



Este desafio tem como objetivo desenvolver uma solução de Engenharia de Dados, que deverá abranger os seguintes tópicos: extração de dados, ingestão de dados, armazenamento de dados, observabilidade, segurança de dados, mascaramento de dados, arquitetura de dados e escalabilidade.

Seu desafio é projetar e implementar uma solução **que possa** lidar com o grande volume de dados. Procure abranger todos os tópicos mencionados nos requisitos.



No dia da apresentação, garanta o completo funcionamento do case (*end-to-end*) para banca, explique a arquitetura proposta, justificando suas escolhas tecnológicas e fornecendo exemplos práticos de como cada aspecto da solução seria implementado. Você pode utilizar como guia uma apresentação detalhada, incluindo diagramas, documentação e explicação de cada componente da solução. Forneça um plano de implementação e considere desafios e melhorias futuras. Lembre-se de que a solução deve ser escalável, segura e eficiente.

O tema abordado pelo case, no que diz respeito aos dados utilizados, é de livre escolha do candidato, por exemplo saúde pública, mercado de ações, estudos demográficos e/ou sociais, mercado de commodities, etc.

Requisitos:

1. Extração de Dados:

- Utilize fontes de dados confiáveis, como dados abertos de órgãos públicos, bolsa de valores ou *datasets* exploratórios. Você também pode trabalhar com geração de dados simulados.
- Considere diferentes formatos de dados, como arquivos CSV, APIs públicas, bancos de dados, etc.

2. Ingestão de Dados:

- Implemente um mecanismo eficiente para a ingestão em lote e/ou contínua e em tempo real dos dados provenientes das diferentes fontes.
- Considere diferentes formas de ingestão, como streaming de dados, ETL (*Extract, Transform, Load*) e arquiteturas (*Kappa, Lambda*).

3. Armazenamento de Dados:

- Escolha uma ferramenta de armazenamento adequada e eficiente para seu case. Saiba diferenciar e justificar o uso de outras possíveis ferramentas ou tecnologias para o armazenamento dos dados, levando em consideração aspectos como volume, velocidade e variedade.
- Avalie opções de armazenamento na nuvem (*cloud*) ou *on-premises*, considerando aspectos de segurança e escalabilidade.

4. Observabilidade:

- Desenvolva uma estratégia de monitoramento e observabilidade da solução, garantindo a capacidade de rastrear o fluxo de dados, detectar falhas e identificar possíveis gargalos de desempenho entre as ferramentas que compõem o(s) pipeline(s) de ingestão.

5. Segurança de Dados:

- Garanta a segurança e confidencialidade dos dados sensíveis dos pacientes, adotando práticas de criptografia, controle de acesso e cumprindo regulamentações de proteção de dados, como a Lei Geral de Proteção de Dados (LGPD).

6. Mascaramento de Dados:


- Proponha técnicas e exemplos de como mascarar dados sensíveis, garantindo a privacidade e anonimização das informações utilizadas na análise.

7. Arquitetura de Dados:

- Projete uma arquitetura de dados escalável que permita o processamento eficiente e uma estrutura de dados adequada para análise.
- Considere o uso de tecnologias como *data lakes*, *data warehouse* e sistemas de processamento distribuído para lidar com o grande volume e variedade de dados.

8. Escalabilidade:

- Garanta que (ou descreva como) a **solução proposta seja capaz de lidar com o aumento contínuo do volume de dados** e a crescente demanda por análises em tempo real.
- Sugira estratégias de **escalabilidade** horizontal e vertical, como a distribuição de carga em clusters de servidores ou o provisionamento de recursos adicionais na nuvem.



Entregáveis:

A seguir são listados os entregáveis mínimos obrigatórios.

1. **Repositório GIT:** Deve ser entregue um repositório público no Github contendo o projeto do case desenvolvido.

O repositório deve possuir um arquivo README com a descrição do case (ver item 2. Relatório)

1. **Relatório:** deve ser entregue um relatório em formato README (Markdown) e deve possuir os seguintes tópicos:

- I. **Objetivo do Case**
- II. **Arquitetura de Solução e Arquitetura técnica**
- III. **Explicação sobre o case desenvolvido**
- IV. **Melhorias e Considerações Finais**

O relatório será avaliado de acordo com a CLAREZA das informações e dos DIAGRAMAS DE SOLUÇÃO, CORRETEDE TÉCNICA e APLICAÇÃO ADEQUADA DA LÍNGUA PORTUGUESA.

Reprodutibilidade da arquitetura:

- O candidato deve garantir que a solução implementada possa ser reproduzida em outra máquina ou ambiente;
- Todos os scripts de configuração, instalação e execução devem estar incluídos no repositório Git;
- O candidato deve incluir instruções claras para a configuração e execução do projeto em outra máquina ou ambiente.

Apresentação do Case:

Durante a apresentação é esperado que o candidato demonstre a solução em funcionamento, apresentando cada uma das partes da arquitetura desenvolvida. O candidato terá 1hr30m (uma hora e trinta minutos) para apresentar o case e responder as perguntas dos avaliadores.

Boa sorte e esperamos que sua solução demonstre um domínio completo dos tópicos de Engenharia de Dados mencionados!